

Progress Report — 阶段一收尾与方法学发现

本文档包含两节：第1节为前次写过的"为什么 *fresh DE* 比 *warm_start* 更可信"的中文版；第2节为新写的"PAC pipeline 方法学发现"章节。两节构成阶段一收尾的方法学讨论部分。

第1节 Fresh DE 为什么比 *warm_start* 更可信

摘要

支撑原 Pareto 分析的 *warm_start* 数据来自一个存在两处确认缺陷的 fitness pipeline：

`s4_personalize_fig7_v7.py` 中随机种子注入不完整，以及一套对模型脉冲型放电率信号在方法学上不适用的 PAC 计算流程（基于 Hilbert 相位 + 互相关时延）。两者都已修复——通过 5 个 Pareto 种子上 bit-identical 的复现性验证确认——之后我们重新跑了一次 deterministic 的 Sobol 全空间初始化 DE，30 代共 4960 次评估，耗时 9.6 小时。Fresh DE 的结果与 *warm_start* 在三个具体方面存在实质性差异，差异本身就是证据：(i) 新 Pareto 前沿从 6 个解收缩到 3 个，(ii) PAC 强度 (MI) 的最大值跃升 5.3 倍，从 0.026 到 0.137，(iii) 原 noisy fitness 选出的"最优"解完全位于新 Pareto 前沿之外。这三点都与"noisy fitness 选出的是噪声辅助下的 feasibility 而非真实参数质量"的假说一致。

1.1 *warm_start* 阶段 fitness pipeline 的两个缺陷

存在两个相互独立的问题影响 *warm_start* 时期的 fitness 评估。两者现已全部修复，且其特征均可被精确刻画。

缺陷 1 —— 随机种子注入不完整。 修复前的 `s4_personalize_fig7_v7.py` 仅对皮层 ALN 节点注入了种子 (`exc_seed=42, inh_seed=42`)，其余三个随机源未被锁定：丘脑节点 (`th[0].seed`)、驱动 TCR/TRN 群体的丘脑 Ornstein-Uhlenbeck 噪声进程、以及 DE 反复调用 `m.run()` 之间的 numba 全局 RNG。这种不对称性带来一个具体后果：皮层 SO 的发放时序——从而 T1-T8 (SO 与纺锤事件类约束)——在 DE 各次评估中近似可复现，而 T9-T11 (PAC 类约束) 由于依赖纺锤包络相对 SO 相位的精确对齐，在评估之间存在显著漂移。我们用 `verify_pareto_seeds.py` 在 5 个 Pareto 种子上做了 deterministic 重评估，实证验证了这种不对称性：种子的 `IBI_CV` 数值与 stage 1 报告值差异为 0.000，但同样这些种子的 MI 数值在同一次评估中漂移了 28% 到 195%。

缺陷 2 —— PAC pipeline 与脉冲型信号的不兼容。 V7 原 PAC pipeline 沿用了 Canolty (2006) / Tort (2010) 提出的标准方法：用 4 阶 Butterworth 带通滤波 SO 信号，通过 Hilbert 变换提取瞬时相位，并通过纺锤包络与 SO 滤波信号互相关峰值的时延评估 SO→spindle 方向性。这一 pipeline 的两个核心假设被我们模型产生的放电率信号违反。**第一**，Bedrosian 定理要求信号近似窄带且接近正弦；模型的脉冲型 SO (约 120 ms UP 态 + 约 1100 ms DOWN 态) 两者都不满足。长 DOWN 态静默使 Hilbert 相位在 $\pm\pi$ 区域过采样约 3.3 倍，系统性扭曲了 modulation index 估计。**第二**，当两个信号都在 SO 频带内有显著能量时，互相关峰值时延在数学上必然是 SO 周期性函数。我们检查了 V7 实际仿真的互相关曲线：曲线包含三个局部最大值，相互之间高度差异不超过 4%，且间隔恰好为一个 SO 周期 (约 1400 ms)；`argmax` 在它们之间的选择本质上由噪声决定。因此 T11 (`lag` ≥ 20 ms) 实际上不是方向性测度，而是一个在周期性地形上的随机硬币翻转。

缺陷 2 的修复其实在 `warm_start_de_with_fixed_pac.py` 里已经做过了 (即"fixed PAC" pipeline：peak-anchored 逐周期相位插值 + up-down 振幅比替代 `xcorr-lag`)，这就是为什么

warm_start fitness 部分可信。但 fixed PAC 跑在一个仍然受缺陷 1 影响的 build_model 之上——所以 PAC 测量在公式上 deterministic、在执行上仍 stochastic。两个缺陷叠加，才是原 Pareto 前沿不可靠的根本原因——单独缺陷 1 引入噪声，单独缺陷 2 引入偏倚，二者结合既有噪声又有偏倚。

修复完两个缺陷后，5 个 Pareto 种子上同一参数向量做 3 次独立 PAC 仿真，MI / up_down_ratio / phase_argmax 的复现精度为 bit-identical (`test_seed_reproducibility.py` 验证)。

1.2 Fresh DE 协议

为了重建一个可信的 stage 1 基线，我们用修复后的 pipeline 从头跑了一次 V7：

- 不使用 warm-start：初始种群是 8 维参数 box 上的 Sobol 均匀采样，使搜索过程与任何由 noisy fitness 选出的解完全解耦。
- 30 代 × 种群 160 = 4960 次评估：与原 V7 evolution 协议完全一致（V7 docstring §change #6），唯一的区别是种子注入与 PAC pipeline 的修复。
- 挂钟时间 9.56 小时（同一台机器，相对 warm_start 的约 2 小时是 4× 代价，反映了重新探索完整参数空间的成本）。

输出：364 个 feasible 解（评估中占 7.3%），最优 score 为 0.7759。

1.3 两次运行的三个实质性差异

Warm_start 与 fresh DE 的逐项对比：

指标	warm_start (noisy)	fresh DE (deterministic)
总评估数	3360	4960
Feasible 解数	302 (9.0%)	364 (7.3%)
最高 fitness score	0.7926	0.7759
Pareto-optimal 子集	6	3
Feasible 中 shape_r 最大值	0.647	0.690
Feasible 中 MI 最大值	0.026	0.137
Feasible 中 up_down_ratio 最大值	2.26	6.90
Feasible 中 MI 中位数	0.0087	0.0151

表中的三个模式都具有诊断意义。

(a) Pareto 前沿从 6 个收缩到 3 个。在 noisy pipeline 下，6 个解看起来 non-dominated。在 deterministic pipeline 下只有 3 个真正 non-dominated。消失的 3 个解在 warm_start 数据里之所以 Pareto-optimal，是因为它们的 noise-inflated PAC 值让它们看起来不被任何解支配；而在

deterministic PAC 测量下，它们 collapse 进了被支配的 bulk 区域。剩下的 3 个——真正的极值 trade-off 点——对 pipeline 修复鲁棒。

(b) PAC 强度最大值 5 倍跃升，同时 shape_r 也提升。 如果 fresh DE 仅仅是"与 warm_start 不同"，那它在各项指标上应该有升有降、大致相当。但实际上 fresh DE 的最佳解在 shape_r (+7%) 和 PAC (max MI +426%) 两个维度上都严格优于 warm_start。这排除了"fresh DE 只是把一个目标换成另一个目标"的解释——它确实找到了 warm_start 搜索从未触及的参数空间区域。最强 PAC 解 (Seed A : MI = 0.137) 对应的 regime，我们之前在 `sobol10_feasibility_check.py` 的均匀采样里偶然瞥见过 (样本 #3, #4 : MI $\approx$ 0.10)，但 warm_start 因为初始化锚定在已知好解附近的 $\pm 2\%$ 邻域，根本到不了那里。

(c) 原"最优"解位于新 Pareto 前沿之外。 Warm_start 阶段的最优解 (V8 saved-best, score = 0.7926) 在新的 (shape_r, PAC_compound) 散点图中位于内部，被 Seed B 和 Seed C 同时支配。这是个独立证据，证明标量 fitness 函数即使被正确计算，也不会选出 Pareto-optimal 点——它只会选出 trade-off 的某个特定加权切片。这个诊断在 warm_start 数据里就已经存在；fresh DE 让它更可信，因为现在所有解的排序都是 noise-free 的。

1.4 本节不主张的内容

为方法学诚信起见，明确指出 fresh DE 结果不能支撑的三个主张：

- **Fresh DE 的 best score (0.7759) 不是"比 warm_start 的 0.7926 差"。** 两个 score 是用不同的 fitness 函数算的 (warm_start 时期受缺陷 1 污染的 PAC vs fresh DE 的 deterministic PAC)，不可直接比较。score 偏低反映了 noise-assisted score inflation 的消失，不是解本身变差。
- **Fresh DE 不一定找到了全局最优。** 由于 deterministic feasibility 更严苛 (7.3% vs 9.0%)，可能继续跑更多代会发现更多 Pareto-optimal 点。但 fitness 曲线在第 16 代后 plateau (best=0.7759 直到第 30 代未变)，说明 DE 在当前标量目标下已经饱和。
- **Fresh DE 的 Pareto 前沿仍是"每参数组合一个单点估计"。** 与 warm_start 一样，它给出的是每个参数向量对应一个 fitness 数值，不是分布。进入 SBI (参数联合后验 + 显式不确定性量化) 的论据不受这些结果影响——如果有什么变化，那就是它强化了：即使是修复后的 pipeline，与污染版本相比也会产生定性不同的最优解，这本身就揭示了单点优化对 fitness 设定的高度敏感性。

1.5 对 Stage 2 的含义

Stage 2 (SBI / SNPE) 将使用 fresh DE 的 3 个 Pareto 种子作为 informative prior 的中心，取代之前 warm_start 的 6 个种子。这 3 个种子覆盖了实证观测到的 trade-off 范围 (Seed A : MI=0.137, shape_r=0.666 ; Seed C : MI=0.029, shape_r=0.690)，且每个都已验证 deterministic 可复现。前次的 5 种子物理验证图 (`fig_pareto_seeds_verification.png`) 已被本节分析取代。

第2节 方法学发现：神经群放电率信号上的 PAC pipeline 失效

2.1 发现的语境与价值定位

V7 fitting pipeline 的开发过程中，我们独立发现了**两个主流 PAC 测量方法在脉冲型神经群信号上系统性失效**的具体机制，并各自给出了正确的修复。这两个发现不是通过文献综述得知的一一文献中尚未有专门讨论一一而是通过实际的 fitting 失败模式追溯出来的。本节将这两个发现合并陈述，因为它们指向同一个根本问题：**计算神经科学社区广泛使用的 PAC pipeline (Canolty 2006; Tort 2010) 是为头皮 EEG 设计的，把它直接套用到神经群放电率信号上会同时引入偏倚和噪声放大。**

发现这件事的方法学意义，比修复这件事本身更重要。N3 期睡眠的数字孪生研究方向上，神经质量模型生成的脉冲型放电率信号正越来越多地被用于替代或补充 EEG 数据；如果不识别 pipeline 失效，整个 fitting/inference 流程的所有 PAC-相关结论都会受污染。

下面分两个 bug 各自详述：发现过程、机制分析、代码层面的修复。

2.2 Bug 1：Hilbert 相位估计在脉冲型 SO 信号上的失效

2.2.1 发现过程

最初的 V7 fitness 函数采用了文献中的标准 PAC pipeline。 `s4_personalize_fig7_v7.py` 在修复前的 PAC 计算包含以下关键步骤：

```
python

# Standard Canolty/Tort PAC pipeline
sos_so = butter(4, [0.5, 1.5], btype='band', fs=fs, output='sos')
so_filt = sosfiltfilt(sos_so, r_ctx)          # 带通滤波 SO 信号
so_phase = np.angle(hilbert(so_filt))        # Hilbert 提取瞬时相位
# 然后用 so_phase 对 spindle 包络做 18-bin 直方图，算 KL-MI 和 MVL 角度
```

在 warm_start 的 Pareto 种子上做物理验证时 (`verify_pareto_seeds.py`)，我们观察到 Seed A 在 stage 1 报告的 preferred phase 是 -135° (slow spindle regime)，但同样参数 deterministic 重跑后测得 MVL 角度漂移到接近 $\pm 180^\circ$ 。把 18-bin 振幅分布的样本数画出来，问题立刻显现： $\pm\pi$ 附近的 phase bin 样本数比中心 phase bin 高 3.3 倍。

2.2.2 机制分析

Hilbert 变换提取的“瞬时相位” $\phi(t) = \angle\{x(t) + j\hat{x}(t)\}$ 只有在两个前提下才有明确物理意义：

1. **Bedrosian 条件**：信号 $x(t)$ 必须近似窄带、近似正弦，使得包络与相位可被良好分离；
2. **常速度条件**：信号的“角速度” $d\phi/dt$ 在所有时段大致连续，没有因信号停滞而退化。

V7 模型生成的皮层 $r_E(t)$ 信号违反了第二条。N3 期 SO 的形态是**窄 UP 态 + 长 DOWN 态**——典型的 120 ms 高发放后，跟着约 1100 ms 接近零的静默。在 DOWN 态期间， $r_{ctx}(t)$ 接近常数 0，其 Hilbert 解析信号 $r + j\hat{r}$ 的角速度退化（接近 0/0 形式）。结果是：

Hilbert 相位在 DOWN 态期间“卡”在某个固定相位附近，导致 $\pm\pi$ 区域被严重过采样——具体倍数取决于 DOWN/UP 时长比，在我们模型上为约 3.3。

下游一切基于该 **phase** 序列的 PAC 测度都被这个采样偏倚污染：

- **MVL (Canolty 2006 mean vector length)** : $MVL = \frac{1}{N} \sum_n A_{sp}(n) e^{j\phi_{so}(n)}$ 的角度是矢量平均，被 $\pm\pi$ 过采样 bin 主导；
- **Tort KL-MI** : 18-bin 概率分布的非均匀性受不均匀采样污染，使得 MI 估计在双峰耦合分布上偏离真实值。

所以即使模型的真实 SO-spindle 耦合存在并且在 **t-domain** 是清晰的，Hilbert pipeline 测出的 "preferred phase" 和 "MI" 都会偏离真实值。这是个 **确定性的方法学偏倚**，不是统计误差，无法通过增加仿真时长消除。

2.2.3 修复

正确的修复 **绕开 Hilbert 变换**，改用基于 SO peak 的逐周期相位定义。

`compute_pac_metrics_fixed.py` 的核心代码逻辑：

```
python

# Peak-anchored cycle-by-cycle phase
peaks, _ = find_peaks(r_ctx, height=UP_THRESH_HZ, distance=int(0.5 * fs))
phase = np.full(len(r_ctx), np.nan)
for k in range(len(peaks) - 1):
    p0, p1 = peaks[k], peaks[k+1]
    # 在相邻两个 UP peak 之间，相位从  $-\pi$  线性插值到  $+\pi$ 
    phase[p0:p1] = np.linspace(-np.pi, np.pi, p1 - p0, endpoint=False)
```

这个定义有三个关键性质：

1. **不依赖 Bedrosian 假设**：不需要信号窄带或近似正弦，直接用 **t-domain** 事件定义相位；
2. **均匀采样保证**：相邻两个 peak 之间不论间隔多长（800 ms 或 1500 ms），都被映射到等长的 $[-\pi, +\pi]$ 区间，每个 phase bin 自动样本均衡；
3. **生理意义直接**：phase = 0 对应 UP peak，phase = $\pm\pi$ 对应两 UP peak 之间的中点（ $\approx$ DOWN 态最深处），这正是 Mölle 2011 等文献使用的相位约定。

`pac["phase_argmax"]` 因此变为对 **振幅分布的众数估计**而非 MVL 矢量平均，对双峰 PAC 分布更鲁棒。

2.3 Bug 2：互相关时延在 SO 周期性信号上的失效

2.3.1 发现过程

V7 原 T11 的实现 (`s4_personalize_fig7_v7.py` 在修复前的相关行)：

```
python
```

```
# T11 directionality via cross-correlation peak lag
xc = correlate(sp_amp - sp_amp.mean(), so_filt - so_filt.mean(), mode="full")
lags = np.arange(-(len(so_filt) - 1), len(sp_amp))
mask = np.abs(lags) <= int(PAC_MAX_LAG_S * fs)      # PAC_MAX_LAG_S = 2.0
peak_lag_samples = lags[mask][np.argmax(xc[mask])]
T11_pass = (peak_lag_samples * 1000 / fs) >= 20.0   # SO leads by ≥ 20 ms
```

V7 的 5 个 Pareto 种子在 deterministic 重评估下，T11 报告的 lag 数值分别为 -1732, -13, -1275, -1459, -1484 ms (`test_seed_reproducibility.py` 的输出)。注意 4/5 解的 lag 都在 -1500 ms 附近——这恰好是负的一个 SO 周期。这不是噪声，是 `argmax` 系统性地选中了"上一个周期"作为最大相关峰。

2.3.2 机制分析

互相关函数 $R_{xy}(\tau) = \int x(t) y(t + \tau) dt$ 通过 Wiener-Khintchine 定理与频谱乘积关联：

$$R_{xy}(\tau) = \mathcal{F}^{-1}\{X^*(\omega) \cdot Y(\omega)\}$$

V7 用来求互相关的两个信号是：

- `so_filt`：经过 [0.5, 1.5] Hz 4 阶 Butterworth 带通的皮层信号——严格窄带，频谱集中在约 0.73 Hz；
- `sp_amp`：纺锤包络（Hilbert 振幅）——如果纺锤被 SO 调制，则包络在 SO 频率处也有显著峰。

两个频谱在 SO 频率处都非零，乘积 $X^* \cdot Y$ 因此也只在 SO 频率附近有显著能量。这意味着——互相关函数的逆变换必然是 SO 频率的近似余弦波，周期 ≈ 1370 ms。这是数学必然，不是模型问题。

实测：我们在与 V7 模型动力学匹配的合成信号上验证，互相关曲线在 ± 2000 ms 窗口内出现 3 个等高峰，高度分别为 0.957 (lag=-1196 ms)、1.000 (lag=+203 ms)、0.959 (lag=+1604 ms)——相互之间高度差异不超过 4%。`argmax` 在它们之间的选择由噪声决定。V7 的 T11 阈值 (lag ≥ 20 ms) 因此实质上不是方向性测度，而是在三个等价峰中"是否运气好选到 +203 那个峰"的随机判断。

更糟的是，4 阶 Butterworth 带通对 120 ms 窄脉冲产生显著的 Gibbs 振铃——单个脉冲被涂抹成跨越约 3 秒的振铃序列。即使没有周期歧义，`so_filt` 的"峰"位置相对于真实 UP 态峰已经偏移约 200-400 ms。20 ms 的方向性精度根本测不出来。

2.3.3 修复

正确的修复完全放弃互相关方法，改用基于相位条件期望的 `up_down_ratio`：

```
python
```

```
# In compute_pac_metrics_fixed.py
# 用上述 peak-anchored phase  $\phi(t)$ , 在相位轴上分段求平均
mask_up    = (np.abs(phase) <= np.pi / 2)      # UP-state phase region ( $|\phi| \leq 90^\circ$ )
mask_down  = (np.abs(phase) > np.pi / 2)      # DOWN-state phase region ( $|\phi| > 90^\circ$ )
amp_up     = sp_amp[mask_up].mean()
amp_down   = sp_amp[mask_down].mean()
up_down_ratio = amp_up / amp_down              # T11 阈值要求  $\geq 1.20$ 
```

这个测度具有三个关键性质：

- 1. **不涉及时序对齐**：是相位条件期望值的比值，而非时间偏移搜索——绕开周期歧义；
- 2. **不涉及 FFT 乘积**：不会继承任何输入信号的周期性——绕开窄带 $\times$ 窄带的数学必然；
- 3. **不涉及带通滤波**：相位 $\phi(t)$ 由 peak detection + 线性插值定义，不引入滤波器群延迟或 Gibbs 振铃。

更重要的是，**方向性自然嵌入这个测度**：UP 态期间 spindle 振幅显著高于 DOWN 态期间，**只可能**来自"SO 状态调制 spindle"这一种因果机制。反向因果（spindle 驱动 SO）不会让一个高频事件去决定低频 SO 的 UP/DOWN 状态。所以不需要"测方向"——比值 > 1 这件事本身就是方向。

2.4 两个 Bug 的共同根源

两个 bug 表面上独立——一个发生在相位估计阶段，一个发生在方向性评估阶段——但根本原因相同：**Canolty (2006) / Tort (2010) 的 PAC pipeline 是为头皮 EEG 设计的**，而 EEG 与神经群放电率信号的统计性质不同：

性质	头皮 EEG (Canolty/Tort 设计基础)	神经群放电率 $r_E(t)$ (V7 模型输出)
信号形态	连续、近平稳、近窄带	脉冲串、非平稳、非正弦
Bedrosian 假设	满足	违反 (DOWN 态静默)
带通滤波后波形保真	高	低 (Gibbs 振铃显著)
xcorr-lag 物理意义	时间延迟代理	被周期性主导 (无意义)

直接套用主流 pipeline 不仅不出 work，而且会**同时**产生方法学偏倚（Bug 1 的 $\pm\pi$ 过采样系统偏倚）和噪声放大（Bug 2 的 argmax 在等高峰之间的随机选择）。

2.5 对睡眠数字孪生研究方向的更广含义

修复方法是简单的（peak-to-peak 相位插值替代 Hilbert，up_down_ratio 替代 xcorr-lag），但**识别问题本身才是关键贡献**。任何后续基于神经质量模型的 N3 fitting 工作都需要先做方法学审查：把头皮 EEG 设计的 PAC pipeline 直接搬到模型生成的放电率信号上，会污染所有 PAC-related 的下游推断。这一点在文献里目前没有专门讨论，应作为方法学贡献写入相关论文。

修复后的 **fitness pipeline** 在 **fresh DE** 的 **deterministic** 验证下，**PAC** 测量的复现性达到 **bit-identical** (**test_seed_reproducibility.py**)，证明修复是闭环正确的。**Stage 2** 的 **SBI** 推断将基于这套修复后的 **PAC** 测度构建似然函数，确保 **posterior** 反映的是真实的参数后验，而非 **pipeline** 偏倚的混淆。